Техническое задание · версия 2.4

ALL-менеджер

SaaS-платформа AI-администратора, который разговаривает как живой — по телефону и в чатах: принимает звонки и сообщения, консультирует, записывает клиентов и передаёт сложное человеку. Продаётся одним звонком на демо-линию.

ДОКУМЕНТ	ВЕРСИЯ	ДАТА	СТАТУС
ТЗ SaaS-платформы	2.4, на основе 2.3	30 октября 2026	Для согласования

Обзор

Содержание

00	О документе	3
01	Продукт	4
02	Глоссарий	6
03	Структура продукта	7
04	Демо-линия	8
05	Реализм диалога	11
06	Мультиарендность, роли и права	14
07	Сайт и регистрация	16
08	Онбординг	18
09	Модерация клиентов	19
10	База знаний	21
11	Анкета компании	23
12	Режимы AI и сценарии	30
13	Государственные поликлиники	32
14	Телефония	35
15	Чаты и соцсети	37
16	CRM: звонки, заявки, календарь	39
17	Аналитика	41
18	Уведомления и интеграции	42
19	Тарифы и биллинг	43
20	Суперадминка и поддержка	45
21	Безопасность и данные	46
22	Нефункциональные требования	48
23	Архитектура и стек	49
24	Контроль качества AI	52
25	Фазы и MVP	54
26	Критерии приёмки	56
27	Риски	59
28	Открытые вопросы	60

Раздел 00

О документе

Версия 2.4 добавляет анкету компании и ответы AI в чатах и соцсетях. В 2.3 добавлены поликлиники, в 2.2 — реализм диалога и демо-линия.

Что изменено относительно v2.1

ОБЛАСТЬ	БЫЛО В V2.1	СТАЛО В V2.4
Главная ценность	Голосовой движок — один модуль из 14	Реализм диалога — ядро продукта и отдельный раздел 5
Путь к покупке	Регистрация → пробный период 7 дней или 30 минут	Звонок на демо-линию → решение → регистрация и оплата
Демо	Звонок из браузера на одного демо-ассистента	Демо-линия: один номер, выбор роли голосом, режим «ваш бизнес» (раздел 4)
Целевая задержка	p50 ≤ 800 мс, p95 ≤ 1500 мс	p50 ≤ 700 мс, p95 ≤ 1200 мс, остановка при перебивании ≤ 200 мс
Фаза 0	Внутренний прототип	Публичная демо-линия — первый рабочий инструмент продаж
Сегменты	Только частный бизнес	+ государственные поликлиники: талоны, лист ожидания, пиковая нагрузка, госзакупки (раздел 13)
Кыргызский язык	Фаза 3	Прототип в фазе 0, в работе с фазы 1; смешанная речь — с фазы 0
Анкета компании	Перечень разделов базы знаний	15 блоков с полями, примерами, уровнями и индексом полноты (раздел 11)
Каналы	Только телефон	+ виджет, Telegram, WhatsApp, Instagram, Facebook, ВКонтакте; одна анкета, единый inbox (раздел 15)

Допущения

Каждое допущение подтверждается у заказчика — вопросы к ним собраны в разделе 28.

- Рынки: Кыргызстан, Казахстан, Россия; языки MVP — русский и кыргызский. Клиенты — бизнес с 20–500 звонками в месяц и поликлиники KG, пилот на календаре платформы.
- Демо-линия бесплатна для звонящего, без видимых ограничений; её стоимость учитывается как расход на привлечение клиента.
- Внешние AI-провайдеры через абстрактный слой, без обучения своих моделей. Ассистент всегда сообщает, что он AI.

Раздел 01

Продукт

ALL-менеджер — мультиарендная SaaS-платформа AI-администратора для звонков и чатов. Он звучит и ведёт разговор как живой администратор: слушает, переспрашивает по делу, не теряет нить, даёт себя перебить. Ассистент принимает звонки 24/7, отвечает по базе знаний компании, записывает клиентов, создаёт заявки и передаёт сложное человеку. Тот же ассистент по той же анкете отвечает в Instagram, WhatsApp, Telegram и на сайте.

1 звонок
до решения о покупке — на демо-линию

≤ 0,7 с
задержка ответа голосом, p50

24/7
приём звонков без выходных

Проблема и ценность

БОЛЬ БИЗНЕСА	КАК ЗАКРЫВАЕТ ПРОДУКТ	МЕТРИКА ЦЕННОСТИ
Клиенты пишут в Instagram и WhatsApp, а ответ получают через час или назавтра	AI отвечает в чатах за секунды и записывает там же	Время первого ответа в чате
Пропущенные звонки в часы пик, вечером, в выходные	AI отвечает на все звонки в пределах лимита линий	Доля отвеченных звонков
В поликлинике один регистратор на сотни звонков, а когда талонов нет — трубку не берут	AI отвечает всегда, в том числе «талонов нет», и ставит в лист ожидания	Доля отвеченных звонков, время ожидания на линии
Голосовые боты раздражают клиентов	Живой темп разговора, перебивание, короткие реплики	Оценка звонков собственником, доля брошенных звонков
Администратор перегружен типовыми вопросами	AI закрывает FAQ, цены, график, адреса	Доля звонков, закрытых без человека
Заявки теряются в блокнотах и мессенджерах	Каждый звонок превращается в карточку в CRM	Доля звонков с созданной заявкой
Собственник не видит качество звонков	Расшифровки, резюме, аналитика, контроль качества	Время до обработки заявки

Целевые сегменты

- **Первая волна** (роли демо-линии и шаблоны в MVP): автосервисы, салоны красоты, стоматологии и частные клиники, сервисные компании, государственные поликлиники и центры семейной медицины.
- **Вторая волна:** магазины, обучение, недвижимость, свадебные салоны, юридические услуги, доставка, B2B-услуги.
- **Не обслуживаются:** категории из стоп-листа платформы (раздел 9.2).

Позиционирование

Продукт продаётся не как «голосовой бот», а как «администратор, который разговаривает как человек и не пропускает звонки». Главный аргумент — не описание на сайте, а звонок: любой может позвонить на демо-линию, выбрать свою сферу и поговорить с ассистентом как клиент. Отличия от конкурентов: реализм диалога, режим «ваш бизнес», встроенная CRM заявок и контроль качества.

Рынки и языки

ПАРАМЕТР	ЗНАЧЕНИЕ
Рынки запуска	Кыргызстан, Казахстан, Россия (подтвердить)
Языки диалога, MVP	Русский, включая смешанную речь; кыргызский (обязателен для поликлиник KG)
Языки диалога, фаза 3	Казахский, английский
Язык интерфейса	Русский, затем английский; i18n закладывается с первого дня
Валюты	KGS, KZT, RUB, USD; цена тарифа хранится по валютам
Часовые пояса	Свой у каждой компании и филиала

Раздел 02

Глоссарий

Термины ниже используются во всём документе только в этом значении.

ТЕРМИН	ЗНАЧЕНИЕ
Платформа	SaaS-сервис ALL-менеджер целиком
Компания (тенант)	Бизнес, подключивший платформу; единица изоляции данных и биллинга
Звонящий	Конечный клиент бизнеса, который звонит по телефону
Талон	Слот приёма у врача в поликлинике; открывается партиями по графику учреждения
Лист ожидания	Очередь звонящих на талон, которого сейчас нет; при освобождении слота — SMS или перезвон
МИС	Медицинская информационная система учреждения или государственная система электронной записи
Демо-линия	Публичный номер платформы, на котором любой может поговорить с ассистентом в выбранной роли
Линия	Один одновременный разговор; лимит линий задаётся тарифом
Минута	Единица тарификации звонков: длительность разговора, округлённая вверх до 15 секунд
Диалог	Единица тарификации чатов: переписка с одним клиентом в одном канале в пределах 24 часов
Канал	Источник обращений: телефон, виджет, Telegram, WhatsApp, Instagram и другие
Анкета	Структурированный опросник о компании из 15 блоков, из которого строится база знаний
Индекс полноты	Доля заполненной анкеты с учётом веса блоков, 0–100%
Перехват	Оператор берёт чат на себя, AI в этом диалоге молчит
База знаний (БЗ)	Данные компании, на основе которых отвечает ассистент
Заявка	Задача на обработку, созданная по звонку или вручную
Суперадмин	Сотрудник владельца платформы с доступом к внутренней админке

Раздел 03

Структура продукта

Продукт состоит из 18 модулей с общим ядром: аутентификация, тенанты, права, аудит. Колонка «Фаза» показывает, когда модуль появляется (раздел 25).

МОДУЛЬ	ДЛЯ КОГО	ЧТО ДЕЛАЕТ	ФАЗА
Демо-линия	Потенциальные клиенты	Звонок на один номер, выбор роли, живой тестовый диалог, итог в SMS	0
Голосовой движок	Звонящий	Диалог в реальном времени с требованиями к реализму	0
Телефония	Платформа	Номера, переадресация, перевод, запись	0–1
Кабинет компании	Собственник, сотрудники	Настройка, звонки, заявки, аналитика, биллинг	1
Мастер онбординга	Новый клиент	Пошаговый запуск ассистента за 30–60 минут	1–2
База знаний	Собственник	Услуги, цены, FAQ, документы, версии	1
CRM заявок	Администраторы	Карточки звонков, заявки, статусы	1
Уведомления	Сотрудники	Telegram, email, push, SMS	1
Контроль качества AI	Платформа, собственник	Eval-набор, слепой тест, оценка звонков	0–1
Суперадминка	Команда платформы	Компании, демо-линия, модерация, мониторинг	1
Биллинг	Собственник, бухгалтер	Подписки, минуты, счета, оплата	1–2
Публичный сайт	Потенциальные клиенты	Ведёт на демо-линию, тарифы, регистрация	2
Календарь и запись	Администраторы, AI	Слоты, запись, перенос, отмена; для поликлиник — талоны	1–2
Анкета компании	Собственник	15 блоков данных о компании, индекс полноты, проверка вопросами	1
Чаты и соцсети	Клиенты, операторы	AI в виджете, Telegram, WhatsApp, Instagram; единый inbox, перехват	1–2
Лист ожидания	Поликлиники, клиники	Очередь на талоны, автоматическое SMS или перезвон при освобождении	1
Аналитика	Собственник	Воронка звонков, качество, причины передачи	1–3
Интеграции и API	Компании, партнёры	CRM, таблицы, календари, вебхуки, REST API	2–3

Раздел 04

Демо-линия

Демо-линия — главный инструмент продаж. Один номер, на который потенциальный клиент звонит, выбирает сферу и разговаривает с ассистентом так, как будто звонит в свой автосервис или клинику. Пробного периода нет: этого звонка достаточно для решения.



Сценарий демо-звонка

1. **Приветствие.** «Здравствуйте! Это демо ALL-менеджера, я AI-администратор. Звонок записывается. Кем мне сегодня быть: автосервисом, клиникой, салоном красоты, стоматологией, поликлиникой — или назовите свою сферу».
2. **Выбор роли.** Голосом в свободной форме («давай как будто я в шиномонтаж звоню») или кнопкой 1–6. Если сфера не из списка — ассистент берёт универсальную роль и называет её.
3. **Вход в роль.** «Отлично, я администратор автосервиса „Мотор“. Звоните как клиент». Дальше — обычный разговор: цены, свободное время, запись, перенос, жалоба, просьба соединить с мастером.
4. **Выход из роли** по фразе «стоп» / «выйти из демо» или после завершения сценария. Ассистент коротко говорит, что сделал бы в реальной работе: «Я бы создал заявку и записал вас на субботу 11:00, администратор получил бы уведомление в Telegram».
5. **Смена роли** без перезвона: «А теперь давай как клиника».
6. **Итог.** Ассистент спрашивает разрешения отправить итог звонка. После согласия — SMS или Telegram со ссылкой на страницу результата: расшифровка, карточка звонка и заявка в том виде, как их видит бизнес в CRM, кнопка «Подключить».

Демо-роли

РОЛЬ	ВЫМЫШЛЕННАЯ КОМПАНИЯ	ЧТО СТОИТ ПОПРОБОВАТЬ
Автосервис	«Мотор», 2 бокса, 6 мастеров	Записаться на замену масла, спросить цену диагностики, перенести запись
Клиника	«Медцентр Ала-Тоо», 8 врачей	Записаться к терапевту, спросить о подготовке к анализам, попросить врача
Салон красоты	«Лаванда», 5 мастеров	Записаться на стрижку к конкретному мастеру, узнать цену окрашивания
Стоматология	«Улыбка», 4 врача	Узнать цену винира, пожаловаться на боль, попросить срочный приём
Поликлиника	«Городская поликлиника № 7», 12 участков	Записаться к терапевту, когда талонов нет; встать в лист ожидания; поговорить по-кыргызски
Универсальная	Название по сфере звонящего	Любой типовой звонок; цены и детали — правдоподобные, с пометкой «пример»

- Демо-чат (фаза 2): те же роли в Telegram-боте и виджете на сайте.
- Каждая роль — полноценная БЗ по разделу 10: услуги с ценами, сотрудники, график, правила записи, свободные слоты на ближайшие 14 дней, FAQ, стоп-темы.
- Слоты демо-роли живые: если звонящий записался на субботу 11:00, при следующем звонке это время занято.
- Роли проходят тот же eval-набор, что и ассистенты клиентов (раздел 24). Демо-линия — витрина качества, на ней ошибки дороже.
- В MVP — 5 ролей и универсальная, в фазе 2 — не менее 10.

Режим «ваш бизнес» (фаза 2)

Самый сильный аргумент: собственник слышит ассистента от имени своей компании до регистрации.

1. На сайте человек вводит ссылку на сайт, 2ГИС или Instagram компании и номер телефона.
2. Автозаполнение (раздел 8) за 2–5 минут собирает услуги, цены, адреса, график.
3. Человек получает 4-значный код и звонит на демо-линию. Ассистент по номеру или коду понимает, чью компанию играть.
4. Ассистент говорит от имени компании: её названием, услугами, адресом. Неизвестные цены и детали не выдумывает, а говорит, что «уточнит администратор».
5. Демо-БЗ хранится 7 дней, видна только этому номеру. При регистрации переносится в черновик БЗ компании — онбординг начинается не с нуля.

«Без ограничений» для звонящего, защита для платформы

Звонящий не видит лимитов, таймеров и счётчиков минут. Платформа защищает себя невидимыми ограничителями:

ОГРАНИЧИТЕЛЬ	ЗНАЧЕНИЕ (ОРИЕНТИР)	ЧТО СЛЫШИТ ЗВОНЯЩИЙ
Длительность одного звонка	15 минут	Ассистент мягко подводит итог и предлагает перезвонить
Звонков с одного номера	5 в сутки, 60 минут в месяц	После лимита — короткое сообщение и предложение оставить заявку на демо с менеджером
Скрытый номер	Не обслуживается	«Перезвоните, пожалуйста, с открытого номера»
Пул демо-линий	Отдельный от клиентов, 20 линий	Очередь до 30 секунд, затем «все линии заняты, перезвоните через минуту»
Дневной бюджет демо	Задаёт суперадмин	Алерт команде при 80%; при 100% — только очередь
Злоупотребление	Молчание, мат, prompt-injection, перебор ролей без диалога	Вежливое завершение звонка, номер в список проверки

Демо-звонок как лид

- В суперадминке каждый демо-звонок — лид: номер, выбранные роли, длительность, итог, отправлен ли результат, перешёл ли на сайт, зарегистрировался ли.
- Писать или звонить лиду можно только после согласия в конце демо-звонка; ссылка из SMS ведёт на регистрацию с уже подставленными номером и сферой.

Метрики демо-линии

МЕТРИКА	ЧТО ПОКАЗЫВАЕТ	ОРИЕНТИР
Средняя длительность	Вовлечённость	≥ 3 минут
Доля звонков с выходом из роли и итогом	Звонящий дошёл до конца сценария	≥ 50%
Конверсия демо → регистрация	Убеждает ли звонок	≥ 15%
Конверсия демо → оплата	Главная метрика продаж	≥ 5%
Себестоимость демо-звонка	Цена касания	$0,3–1,5
Стоимость привлечения через демо	Расход демо / оплаты	Ниже 1 месяца подписки «Старт»

Раздел 05

Реализм диалога

Реализм — главный фактор продажи и доверия. Ассистент должен разговаривать как опытный администратор: в живом темпе, коротко, без пауз «робота», с умением слушать и быть перебитым. Требования ниже измеримы и подтверждаются в фазе 0, до разработки остального продукта.

Целевые показатели

ПОКАЗАТЕЛЬ	ЦЕЛЬ	ПРЕДЕЛ
Задержка ответа после конца фразы звонящего, p50	≤ 700 мс	≤ 900 мс
То же, p95	≤ 1200 мс	≤ 1500 мс
Время до приветствия после соединения	≤ 700 мс	≤ 1 с
Остановка речи AI при перебивании	≤ 200 мс	≤ 300 мс
Ложные перебивания: AI заговорил, пока звонящий не закончил	≤ 3% реплик	≤ 5%
Ошибки распознавания (WER), русский, телефон	≤ 10%	≤ 15%
Точность телефонов, дат, имён после подтверждения	≥ 98%	≥ 95%
Естественность (MOS, слепой тест)	≥ 4,3	≥ 4,0
Разрыв MOS с живым администратором	≤ 0,3	≤ 0,5
Повтор одинаковой фразы в одном звонке	0	≤ 1 раз

Поведение как у живого администратора

- **Очерёдность реплик по смыслу.** Конец фразы определяется по смыслу и интонации, а не по фиксированной паузе. «Мне бы на… э-э… в субботу» — это не конец фразы.
- **Бэкченнелинг.** Пока звонящий объясняет длинно, AI вставляет короткие «угу», «да-да, слушаю» — не чаще одного раза в 4–6 секунд и не поверх важных слов.
- **Перебивание посреди слова.** AI замолкает, слышит, что сказал звонящий поверх его речи, и отвечает на это, а не продолжает заготовку.
- **Короткие реплики.** 1–2 предложения. Списки не зачитываются: «Есть три варианта по цене — от 1500 до 4000. Рассказать подробнее?»
- **Разнообразие.** Подтверждения и связки не повторяются дословно; одна и та же мысль звучит разными словами.
- **Память разговора.** AI не переспрашивает уже сказанное и понимает поправки: «нет, не в пятницу, в субботу».

- **Паузы и отвлечения.** «Секунду», фоновый разговор, молчание до 10 секунд — AI ждёт или мягко переспрашивает, не начинает сначала.
- **Подстройка под звонящего.** Раздражённому — спокойнее и короче; пожилому — медленнее и чётче; торопливому — сразу к делу.
- **Филлеры при долгих операциях.** «Секунду, смотрю свободное время» — только если операция дольше 1 секунды.
- **Естественная речь чисел.** «В половине одиннадцатого», «полторы тысячи», телефон — группами по 3–2–2 цифры.
- **Смешанная речь.** Понимает русскую речь с кыргызскими и казахскими словами и местными названиями улиц, районов, ориентиров.
- **Телефонный звук.** Работа на 8 кГц аудио, шумоподавление, распознавание DTMF.

Архитектура диалога

ВАРИАНТ	ПЛЮСЫ	МИНУСЫ
Каскад: потоковый STT → LLM → потоковый TTS	Контроль на каждом шаге, дешевле минута, лучший провайдер под язык	Сложнее уложиться в 700 мс, интонации беднее
Speech-to-speech (realtime-модели)	Минимальная задержка, живые интонации, естественное перебивание	Дороже минута, меньше контроля, слабее для кыргызского и казахского
Гибрид: s2s ведёт речь, действия — через функции на сервере	Реализм s2s и проверяемые действия	Сложнее отладка, два контура логики

Фаза 0 проверяет все три варианта на одних и тех же сценариях и выбирает по двум критериям: реализм (раздел 5.4) и себестоимость минуты (раздел 19.3). Для демо-линии допустим более дорогой вариант, если он заметно выигрывает в реализме.

Обязательно в любом варианте: абстрактный слой провайдеров с автоматическим переключением на резервный, функции на сервере для всех действий, запись двух каналов.

Как измеряется реализм

1. **Слепой тест.** 20 слушателей из целевой аудитории, по 30 пар записей на роль: один и тот же сценарий проходят AI и живой администратор. Слушатель оценивает естественность от 1 до 5 и выбирает, какой звонок приятнее.
2. **Метрики из логов** на каждом звонке: задержки, ложные перебивания, повторы вопросов, повторы фраз, длина реплик.
3. **Регрессия.** Слепой тест — на каждый релиз движка, промптов или провайдера; автоматические метрики — на каждый eval-прогон (раздел 24).
4. **Демо-линия как полигон.** Звонки, брошенные в первые 30 секунд, и звонки с низкой оценкой разбираются еженедельно.

Голос

- Не менее 4 голосов на каждый язык, выбор в кабинете с прослушиванием.
- Словарь произношения для названий компании, услуг, улиц.
- Длительность звонка по умолчанию до 10 минут, затем AI предлагает заявку.
- Клонирование голоса реальных людей не поддерживается.

Реализм — не обман. В приветствии AI сообщает, что это AI-ассистент, — отключить нельзя. На вопрос «вы робот?» AI всегда отвечает честно. Ассистент звучит как живой администратор, но не выдаёт себя за человека.

Раздел 06

Мультиарендность, роли и права

Каждая компания — изолированный тенант. Ни один запрос, отчёт или ответ AI не может вернуть данные другой компании.

Иерархия

1. **Организация** — владелец, общий биллинг для сети (корпоративный тариф).
2. **Компания** — тенант: своя база знаний, номера, ассистент, CRM.
3. **Филиал** — адрес, график, сотрудники, свои номера и, при необходимости, своя часть БЗ.
4. **Пользователь** — может состоять в нескольких компаниях с разными ролями.

Демо-роли и демо-БЗ режима «ваш бизнес» живут в отдельном служебном тенанте платформы и не смешиваются с данными клиентов.

Изоляция данных

- В каждой таблице с данными клиента есть поле tenant_id; доступ ограничен на уровне БД (Row-Level Security в PostgreSQL), а не только в коде.
- Векторный индекс базы знаний разделён по тенантам; фильтр проверяется на сервере.
- Аудио и файлы хранятся с префиксом тенанта; доступ только через подписанные ссылки сроком до 15 минут.
- Автотест изоляции: попытка прочитать чужие данные любым API-эндпоинтом возвращает 404. Тест обязателен в CI.

Матрица прав

ДЕЙСТВИЕ	СОБСТВ.	АДМИН	СОТРУДНИК	БУХГАЛТЕР
Видеть звонки и заявки	Да	Да	Свои	Нет
Слушать аудио и расшифровки	Да	Да	Свои	Нет
Менять статусы заявок	Да	Да	Свои	Нет
Редактировать базу знаний	Да	По разрешению	Нет	Нет
Публиковать БЗ и настройки AI	Да	Нет	Нет	Нет
Включать и выключать AI	Да	Да	Нет	Нет
Сотрудники и роли	Да	Нет	Нет	Нет
Тариф, оплата, счета	Да	Нет	Нет	Да

ДЕЙСТВИЕ	СОБСТВ.	АДМИН	СОТРУДНИК	БУХГАЛТЕР
Экспорт и удаление данных	Да	Нет	Нет	Нет

Суперадмин видит звонки только с записью в аудит-лог, слушает аудио по заявке в поддержку, может принудительно выключить AI. Собственник создаёт свои роли из набора прав (фаза 3). Передача прав собственника требует подтверждения по email.

Аудит-лог

- Логируются: вход, изменения БЗ, публикации версий, настройки AI, статусы заявок, права, тариф, экспорт, удаление, действия суперадмина внутри компании.
- Запись: кто, когда, IP, объект, значение до и после.
- Лог неизменяемый, хранится не менее 1 года, доступен собственнику.

Аутентификация

- Вход по email и паролю, по коду в SMS или Telegram, через Google.
- Двухфакторная аутентификация обязательна для собственника и суперадмина.
- Список активных сессий, выход со всех устройств.
- SSO (SAML/OIDC) для корпоративного тарифа — фаза 4.

Раздел 07

Сайт и регистрация

Сайт ведёт к одному действию — звонку на демо-линию. Регистрация и оплата идут после звонка, а «запросить демо с менеджером» остаётся для крупных клиентов.

Страницы

СТРАНИЦА	СОДЕРЖАНИЕ	ЦЕЛЬ
Главная	Демо-номер крупно на первом экране, кнопка «Позвонить из браузера», записи живых демо-звонков	Звонок на демо
Ваш бизнес	Поле «ссылка на ваш сайт» → код → звонок	Персональное демо
Ниши	Сценарии, что попробовать на демо-линии, что AI делает и не делает	SEO и конверсия
Возможности	Звонки, заявки, запись, аналитика, интеграции	Объяснить продукт
Тарифы	Сравнение, калькулятор минут, FAQ по оплате	Выбор тарифа
Результат демо	Страница из SMS: расшифровка, карточка, заявка, «Подключить»	Регистрация
Безопасность	Хранение, согласия, этические правила	Снять страхи
Блог, кейсы	Контент для SEO	Трафик
Юридические	Оферта, политика ПДн, DPA, допустимое использование	Требование закона

Требования к сайту

- Демо-номер виден на первом экране на любом устройстве и кликабелен на мобильном (tel:).
- Звонок из браузера (WebRTC) идёт в тот же голосовой контур, что и телефонный.
- SSR или статическая генерация, LCP не более 2,5 с на мобильном 4G.
- Мультиязычность (ru, затем ky, kk, en), hreflang, sitemap, мета-разметка.
- События воронки: визит → демо-звонок → результат демо → регистрация → оплата.
- UTM-метки и реферальный код связываются с демо-звонком через номер телефона и сохраняются в компании при регистрации.

Регистрация без пробного периода

1. Регистрация по телефону или email с подтверждением кодом. Если человек пришёл по ссылке из SMS после демо — номер уже подставлен.
2. Создание компании: название, сфера (из выбранной демо-роли), страна, часовой пояс.
3. Сразу доступен тестовый режим: мастер онбординга и тестовые звонки своему ассистенту из браузера — бесплатно, с теми же невидимыми ограничителями, что у демо-линии.
4. Реальная линия — после оплаты первого месяца и модерации.
5. Письма и сообщения жизненного цикла: итог демо, напоминание через 1 и 3 дня после демо без регистрации, напоминание о незавершённом мастере.
6. Защита от злоупотреблений: капча, лимит регистраций с одного IP и устройства, проверка одноразовых email.

Раздел 08

Онбординг

Онбординг доводит клиента до работающей линии без участия команды платформы: свой ассистент звучит через 30 минут после регистрации, реальная линия — в течение 1 рабочего дня, включая модерацию.

Шаги мастера

Шаги 3–7 — это блоки анкеты компании (раздел 11). Мастер проводит по обязательным полям, остальное собственник дозаполняет в кабинете.

1. **Сфера бизнеса** — подгружает шаблон анкеты, FAQ, стоп-темы и сценарии.
2. **Автозаполнение** — сайт, 2ГИС, Instagram или прайс; AI предлагает услуги, цены, адреса, график. Данные из режима «ваш бизнес» переносятся сюда.
3. **Профиль компании** — название, описание, адреса, филиалы, график, праздники.
4. **Услуги и товары** — перечень, цены или диапазоны, длительность.
5. **Правила** — запись, отмена, перенос, предоплата, что AI нельзя обещать.
6. **Ответственные** — кто получает заявки, жалобы и переводы звонков.
7. **Голос и тон** — выбор голоса с прослушиванием, обращение на «вы», приветствие.
8. **Проверка готовности** — индекс полноты анкеты, проверка вопросами, уровень БЗ.
9. **Тестовые звонки и чат** — из браузера или на тестовый номер, без ограничения по количеству; после каждого — итоговая карточка.
10. **Оплата, номер и каналы** — подключение номера, виджета, Telegram, WhatsApp, Instagram и отправка на модерацию.

Подключение номера

СПОСОБ	КАК РАБОТАЕТ	ПЛЮСЫ	МИНУСЫ
Переадресация	Бизнес включает переадресацию у своего оператора	Номер для клиентов не меняется	Нужны инструкции по операторам
Номер платформы	Платформа выдаёт городской или мобильный номер	Запуск за минуты	Новый номер для клиентов
SIP к АТС клиента	Ассистент — внутренний абонент АТС	Гибкая маршрутизация	Нужен специалист по АТС

Активация

Первую неделю — ежедневная сводка с тремя худшими звонками и подсказками для анкеты. Метрика активации: 10 реальных звонков за 7 дней.

Раздел 09

Модерация клиентов

Ассистент не подключается к реальной линии только по факту оплаты. Каждая компания проходит автоматическую проверку, чувствительные ниши — ещё и ручную.

Статусы готовности

СТАТУС	УСЛОВИЕ ВХОДА	ЧТО ДОСТУПНО	ПЕРЕХОД ДАЛЬШЕ
Черновик	Компания создана	Мастер, БЗ	Тестовый режим
Тестовый режим	Обязательные поля заполнены	Тестовые звонки	На модерации
На модерации	Оплата прошла, запрошена реальная линия	Тестовый режим	Разрешён, Ограничен, Правки, Отклонён
Нужны правки	Модератор вернул	Тестовый режим	На модерации
Разрешён запуск	Проверки пройдены	Все функции тарифа	Ограничен, Приостановлен
Ограниченный режим	Риск в нише или БЗ	Только заявки и передача	Разрешён
Приостановлен	Жалоба, неоплата, инцидент	AI выключен, fallback	Разрешён
Отклонён	Нарушение правил	Только экспорт данных, возврат оплаты	—

Категории ниш

КАТЕГОРИЯ	ПРИМЕРЫ	ПОРЯДОК ЗАПУСКА
Стандартные	Автосервис, салон, ремонт, клининг, магазин, доставка	Автопроверка, запуск сразу
Чувствительные	Медицина, стоматология, юристы, финансы, психологи	Ручная модерация за 1 рабочий день
Запрещённые	Нелицензированные азартные игры и займы, «гарантированное лечение», коллекторские обзвоны, политическая агитация	Отказ в регистрации

В режиме «ваш бизнес» запрещённые категории тоже не обслуживаются: ассистент вежливо отказывается играть такую компанию.

Автоматические проверки

- Заполнены стоп-темы и есть ответственный за сложные случаи.
- Для записи указан график; для озвучивания цен цены подтверждены собственником.
- Приветствие раскрывает, что говорит AI-ассистент, и называет компанию.
- LLM-классификатор находит в БЗ гарантии результата, вводящие в заблуждение формулировки, давление, экспертные заключения — и показывает их с цитатами и правкой.

Автоматика помечает риск, но не отказывает сама. **Окончательный отказ всегда утверждает человек.**

Постоянный мониторинг

- Выборочная проверка не менее 5% звонков чувствительных ниш в первый месяц.
- Флаги в звонках: обещание результата, медицинский совет, агрессия, жалоба на обман.
- При 3 подтверждённых нарушениях за 30 дней — ограниченный режим.

Раздел 10

База знаний

Ассистент отвечает только по опубликованной версии базы знаний своей компании. Структурированные данные (цены, график, услуги) имеют приоритет над свободным текстом.

Состав

РАЗДЕЛ	ФОРМАТ	КАК ИСПОЛЬЗУЕТ AI
Профиль, адреса, график	Структурированные поля	Прямые ответы, проверка времени записи
Услуги и товары	Таблица: название, синонимы, цена, длительность	Консультации, запись
Сотрудники	Имя, специализация, график, услуги	Подбор специалиста
FAQ	Вопрос, ответ, синонимы	Типовые вопросы
Документы	PDF, DOCX, TXT, страницы сайта	Поиск по фрагментам (RAG)
Правила	Запись, отмена, предоплата, гарантия, возврат	Ответы и ограничения действий
Стоп-темы	Список с формулировкой отказа	Жёсткие ограничения
Акции	Текст, даты действия	Только в период действия
Манера речи	Обращение, приветствие, принятые в компании формулировки	Тон и словарь ассистента

Все разделы заполняются через анкету компании (раздел 11), документы — загрузкой файлов.

Черновик и публикация

- Изменения вносятся в черновик; ассистент работает на текущей опубликованной версии.
- Перед публикацией — сравнение версий и прогон тестовых вопросов.
- Публикация создаёт неизменяемую версию; откат в один клик.
- В карточке звонка фиксируются версии БЗ и промпта.

Уровни готовности

УРОВЕНЬ	МИНИМУМ ДАННЫХ	ДОСТУПНЫЕ РЕЖИМЫ AI
Низкий	Нет профиля или ответственного	AI не запускается
Базовый	Профиль, график, ответственный, стоп-темы	Только сбор заявок

УРОВЕНЬ	МИНИМУМ ДАННЫХ	ДОСТУПНЫЕ РЕЖИМЫ AI
Средний	+ услуги с ценами, 10+ FAQ	Консультация по базе
Высокий	+ сотрудники, правила записи, календарь	Запись, перенос, отмена

Пробелы в знаниях и поиск

- Вопросы без ответа собираются в отдельный раздел с частотой; ответ в один клик попадает в черновик FAQ.
- Гибридный поиск: векторный + полнотекстовый, с переранжированием. Поиск укладывается в 150 мс, чтобы не съедать бюджет задержки.
- Ниже порога релевантности AI не отвечает по существу, а предлагает передачу человеку.
- Цены и наличие озвучиваются только из структурированных полей.

Раздел 11

Анкета компании

Анкета — это скелет базы знаний: всё, что ассистент знает о компании, он берёт отсюда. Чем подробнее анкета, тем увереннее ассистент отвечает и тем реже передаёт разговор человеку. Анкета одна для звонков и чатов.

Как устроена анкета

- **15 блоков.** У каждого поля есть тип (поле, таблица, список, свободный текст), уровень обязательности, подсказка и пример из шаблона сферы.
- **Уровни.** О — обязательно для запуска; Р — рекомендуется, сильно влияет на качество; Д — дополнительно.
- **Шаблон сферы** подставляет вопросы и примеры под выбранную сферу. Для автосервиса это марки авто и запчасти, для поликлиники — талоны и участки.
- **Автозаполнение** с сайта, 2ГИС, Instagram и из прайса предлагает черновик значений. Собственник подтверждает или правит каждое поле.
- **Индекс полноты** от 0 до 100% считается по весам блоков. Уровень готовности (раздел 10.3) зависит от индекса и обязательных полей.
- **Три способа заполнить:** форма в кабинете (фаза 1), голосом — собственник надиктовывает, AI раскладывает по полям (фаза 2), интервью — AI задаёт вопросы анкеты в чате или по телефону (фаза 2).
- Каждое изменение попадает в черновик и публикуется версией (раздел 10.2).

Порог запуска: реальная линия подключается при индексе полноты от 70% и всех обязательных полях. При индексе ниже 50% доступен только режим «Сбор заявки». Цель для хорошего ассистента — 85% и выше.

Блоки и вес в индексе

БЛОК	ЧТО СОДЕРЖИТ	ВЕС	УРОВЕНЬ
1. Компания	Название, описание, отличия, ссылки	5%	О
2. Филиалы и график	Адреса, ориентиры, как добраться, график, праздники	10%	О
3. Услуги и цены	По строке на услугу: синонимы, цена, длительность, исполнитель	18%	О
4. Сотрудники	Имена, специализация, услуги, график, перевод звонков	8%	Р
5. Запись и правила	Порядок записи, отмена, опоздание, предоплата	10%	О для записи

БЛОК	ЧТО СОДЕРЖИТ	ВЕС	УРОВЕНЬ
6. Оплата и гарантии	Способы оплаты, гарантия, возврат	5%	Р
7. Акции	Условия и сроки, скидки, лояльность	2%	Д
8. Частые вопросы	30–50 вопросов сферы с короткими и подробными ответами	10%	О (10+)
9. Возражения и сложные ситуации	«Дорого», «подумаю», жалоба, конфликт	6%	Р
10. Стоп-темы и границы	Что нельзя обещать и обсуждать, формулировка отказа	5%	О
11. Передача человеку	Кому, когда, как, если никто не ответил	5%	О
12. Манера речи	Имя ассистента, приветствие, тон, языки, стиль в чатах	4%	Р
13. Данные о клиенте	Что спросить обязательно, что не спрашивать	4%	О
14. Примеры диалогов	3–5 удачных звонков или переписок	4%	Р
15. Вопросы сферы	Дополнительные поля шаблона сферы	4%	Р

Блок 1 · Компания

Примеры во всех блоках — из шаблона «Автосервис», вымышленный автосервис «Мотор».

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Название	Как называть в разговоре, ударение	«Мотор» (МО-тор)	О
Короткое описание	1–2 предложения: кто вы и для кого	Автосервис для легковых авто, 2 бокса, Бишкек	О
Сфера	Из списка шаблонов	Автосервис → ремонт и ТО	О
Чем отличаетесь	3–5 аргументов на вопрос «почему вы»	Гарантия 6 мес., оригинальные запчасти, зона ожидания	Р
Ссылки и каналы	Сайт, Instagram, WhatsApp, 2ГИС	instagram.com/motor.kg	Р
Реквизиты	Для вопросов о счетах и документах	ОсОО «Мотор», ИНН	Д

Блок 2 · Филиалы, адреса, график

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Адрес	Улица, дом, этаж, вход	Ахунбаева 120, вход со двора	О
Ориентиры	Как объясняют дорогу местные	Напротив ТЦ «Вефа», за заправкой	Р
Как добраться	Транспорт, парковка	Маршрутки 113 и 140, парковка на 6 мест	Р

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
График	По дням, перерывы	Пн–Сб 9:00–19:00, обед 13:00–14:00	О
Праздники	Даты и режим	31 декабря до 15:00, 1–2 января выходной	Р
Телефоны	Для перевода звонков и SMS	+996 555 000 000	О

Блок 3 · Услуги и цены

Заполняется таблицей, по строке на услугу. Импорт из Excel или прайса; AI сам раскладывает колонки.

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Название	Как в прайсе	Замена масла двигателя	О
Как говорят клиенты	Синонимы, разговорные слова, кыргызский	«поменять масло», «ТО», «май алмаштыруу»	Р
Описание	Что входит, 1–2 предложения простыми словами	Слив, новый фильтр, масло наше или клиента	Р
Цена	Точная, «от–до» или «после осмотра»	От 800 сом + масло	О
Длительность	Для записи	30–40 минут	О для записи
Кто выполняет	Сотрудник или ресурс	Любой мастер, бокс 1 или 2	Р
Ограничения	Подготовка, когда нельзя	Приём не позже чем за час до закрытия	Д
Что предложить вместе	Допродажа без давления	Проверить воздушный фильтр	Д
Чего не делаем	И куда направить	Кузовной ремонт не делаем	Р

Блок 4 · Сотрудники

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Имя для клиентов	Как представлять	Мастер Азамат	О для записи к специалисту
Специализация	Должность, опыт	Моторист, 12 лет опыта	Р
Услуги	Что выполняет	Двигатель, ходовая	О для записи
График	Если отличается от филиала	Вт–Сб 10:00–19:00	О для записи
Языки	На каких говорит с клиентом	Русский, кыргызский	Д
Перевод звонков	Да или нет, номер, часы	Да, 10:00–18:00	Р

Блок 5 · Запись и правила

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Порядок	Только запись, живая очередь или оба	Запись и живая очередь	О
Минимум до записи	За сколько можно записаться	Не раньше чем через 2 часа	Р
Отмена и перенос	Сроки и условия	Бесплатно не позже чем за 3 часа	О
Опоздание	Что происходит	Ждём 15 минут, потом перенос	Р
Предоплата	Когда и сколько	Покраска — 30%	Р
Что взять с собой	Документы, вещи	Техпаспорт	Р
Напоминание	Нужно ли и когда	SMS за сутки	Д

Блок 6 · Оплата, гарантия, возврат

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Способы оплаты	Наличные, карты, кошельки, перевод	Наличные, карта, Элсом, MBank	О
Для юрлиц	Безнал, договор, документы	По счёту, акт выполненных работ	Д
Рассрочка	Есть ли и условия	Нет	Д
Гарантия	На что и какой срок	6 месяцев на работы	Р
Возврат и претензии	Порядок	Через старшего мастера, в течение 3 дней	Р

Блок 7 · Акции и программы

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Акция	Текст и условия	−15% на диагностику по вторникам	Д
Сроки	С какого по какое; после срока AI её не упоминает	До 30 ноября	О, если есть акция
Скидки	Кому и сколько	Пенсионерам −10%	Д
Сертификаты, лояльность	Есть ли и как работают	Каждое 5-е ТО — замена фильтра бесплатно	Д

Блок 8 · Частые вопросы

Шаблон сферы даёт 30–50 типовых вопросов. Собственник отвечает или отмечает «не применимо», а свои вопросы добавляет сам. У каждого ответа две версии: короткая — для звонка, подробная — для чата и просьбы «расскажите подробнее».

ВОПРОС	КОРОТКИЙ ОТВЕТ	ПОДРОБНЫЙ ОТВЕТ
Можно со своим маслом?	Да, работа — 800 сом	Да. Работа 800 сом, фильтр наш или ваш. Масло проверим на допуск по марке авто
Сколько ждать?	ТО — около 40 минут	ТО 30–40 минут, есть зона ожидания с кофе и Wi-Fi. Диагностика — до часа
Работаете с китайскими авто?	Да, со всеми легковыми	Да: Chery, Haval, Geely, BYD и другие. Гибриды берём, электромобили — нет

Минимум для уровня «Средний» — 10 ответов, цель — 30 и больше.

Блок 9 · Возражения и сложные ситуации

Здесь задаётся смысл ответа, а не дословный текст: формулировку ассистент подбирает под разговор.

СИТУАЦИЯ	КАК ОТВЕЧАТЬ	ПРИМЕР
«Дорого»	Объяснить, что входит; предложить дешёвый вариант, если есть	«В цену входит фильтр и проверка ходовой. Можно без проверки — будет 600»
«У других дешевле»	Не обсуждать конкурентов, говорить о своих условиях	«Мы даём гарантию 6 месяцев на работу»
«Я подумаю»	Не давить, предложить удобный следующий шаг	«Могу придержать субботу 11:00 до вечера без предоплаты»
Жалоба	Извиниться, собрать детали, не спорить, срочная заявка	«Понимаю, неприятно. Расскажите, что случилось, — передам старшему мастеру»
Клиент раздражён	Коротко, спокойно, сразу к делу или к человеку	—
Ошибка компании	Что разрешено предложить	Повторная диагностика бесплатно — только по решению мастера

Блок 10 · Стоп-темы и границы

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Нельзя обещать	Сроки, цены, результат без осмотра	Точную цену ремонта двигателя по телефону	О
Не обсуждать	Темы, о которых AI не говорит	Конкуренты, зарплаты, личные номера сотрудников	О
Формулировка отказа	Как вежливо уйти от темы	«Это лучше уточнит мастер — передам ему ваш вопрос»	О
Запретные слова	Чего не говорить никогда	«Дёшево», «гарантированно починим»	Д

Блок 11 · Передача человеку

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Кому и по каким темам	Ответственные по темам	Жалобы — управляющему, кузов — старшему мастеру	О
Когда передавать	Темы и условия сверх обязательных (раздел 12.4)	Скидка, гарантийный случай	О
Как	Перевод звонка, заявка, сообщение	В рабочее время перевод, иначе заявка	О
Если никто не ответил	Что обещать клиенту	Перезвоним до 12:00 следующего дня	О
Что считать срочным	Признаки срочности	Машина не заводится на дороге	Р

Блок 12 · Манера речи

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Имя ассистента	Или без имени	Айгуль	Р
Приветствие	Первая фраза в звонке и в чате	«Автосервис „Мотор“, AI-ассистент Айгуль, слушаю вас»	О
Обращение	«Вы», по имени или без	На «вы», по имени, если клиент назвался	Р
Тон	Официальный, дружелюбный, простой	Дружелюбный, без канцелярита	Р
Слова компании	Как у вас называют вещи	«Бокс», а не «пост»	Д
Языки	Основной и разрешённые	Русский, кыргызский — по языку клиента	О
Стиль в чатах	Эмодзи, длина, ссылки	Без эмодзи, до 3 предложений, ссылка на 2ГИС	Р

Блок 13 · Данные о клиенте

ПОЛЕ	ЧТО УКАЗАТЬ	ПРИМЕР	УР.
Спросить обязательно	Поля заявки и записи	Имя, телефон, марка, модель и год авто	О
Желательно	Если клиент готов сказать	Пробег, VIN	Р
Не спрашивать	Лишние персональные данные	Домашний адрес	Р
Постоянный клиент	Что можно упомянуть	«Вы были у нас в сентябре» — только после подтверждения номера	Д

Блок 14 · Примеры диалогов

- 3–5 удачных звонков или переписок — записью, расшифровкой или текстом. По ним ассистент перенимает тон, порядок вопросов и местные выражения.
- 1–2 примера «как не надо», если есть.
- Персональные данные в примерах маскируются автоматически при загрузке.

Блок 15 · Вопросы сферы

СФЕРА	ДОПОЛНИТЕЛЬНЫЕ ПОЛЯ АНКЕТЫ
Автосервис	Марки и типы авто; запчасти свои или клиента; эвакуатор; зона ожидания; платная ли диагностика
Салон красоты	Уровни мастеров и разница в цене; материалы и бренды; тест на аллергию; детские услуги
Стоматология, клиника	Первичная консультация; снимки и анализы; врачи по направлениям; что делать при острой боли; документы
Поликлиника	Участки и адреса прикрепления; когда открываются талоны; кабинеты и врачи; что бесплатно по ОМС, что платно; документы (паспорт, полис); вызов на дом — часы и условия; справки
Сервисные компании	Зона выезда, стоимость выезда, срочный вызов, гарантия на работы

Проверка анкеты

1. **Проверка вопросами.** Перед публикацией AI прогоняет 30 типовых вопросов сферы по черновику, показывает, на какие ответить не может, и ведёт к нужному полю.
2. **Противоречия.** Разные цены, графики или условия в разных блоках подсвечиваются до публикации.
3. **Тестовый звонок и тестовый чат** после каждой публикации, без ограничений.
4. **Пробелы из жизни.** Раз в неделю приходит список вопросов клиентов без ответа из звонков и чатов. Ответ в один клик попадает в анкету.

Раздел 12

Режимы AI и сценарии

LLM понимает речь и формулирует ответы, но действия (запись, заявка, перевод) выполняются только через описанные функции с проверкой на сервере.

Режимы автономности

РЕЖИМ	ЧТО ДЕЛАЕТ AI	УРОВЕНЬ БЗ	ТАРИФ
Сбор заявки	Выясняет запрос и контакты, создаёт заявку	Базовый	Все
Консультация	+ отвечает по базе знаний	Средний	Все
Запись	+ записывает, переносит, отменяет	Высокий	Бизнес+
Полуавтомат	+ исходящие подтверждения, обзвон пропущенных	Высокий	Профи+

Быстрый переключатель в шапке кабинета: **«Включён», «Только заявки», «Всё человеку», «Выключен»**. Применяется к новым звонкам в течение 10 секунд.

Сценарий входящего звонка

1. Приветствие: компания, что говорит AI-ассистент, при необходимости — о записи разговора. Не длиннее 6 секунд.
2. Определение цели: запись, консультация, товар, жалоба, перенос, другое.
3. Узнавание звонящего по номеру — с подтверждением, без раскрытия данных постороннему.
4. Уточняющие вопросы по сегменту, без повтора уже сказанного.
5. Ответ только в рамках БЗ и разрешённого режима.
6. Действие: запись, заявка, перевод или задача на перезвон.
7. Подтверждение вслух — коротко и естественно: «Записала вас на субботу, 11:00, к Айгерим. Всё верно?»
8. Завершение с понятным итогом.
9. После звонка: аудио, расшифровка, резюме, карточка, уведомление.

Типы обращений

ТИП	ЧТО СОБИРАЕТ AI	ИТОГ	ПРАВИЛО
Запись	Услуга, филиал, специалист, дата, время, контакты	Запись или заявка	Только свободные слоты

ТИП	ЧТО СОБИРАЕТ AI	ИТОГ	ПРАВИЛО
Консультация	Вопрос	Ответ или вопрос специалисту	Нет в БЗ — не придумывать
Товар	Товар, бюджет, срочность, получение	Заявка на проверку	Наличие не обещать
Жалоба	Суть, когда, с кем, ожидания	Заявка высокого приоритета	Не спорить
Перенос, отмена	Какая запись, новое время, причина	Обновлённая запись	Поиск по номеру
Нецелевой	Причина	Пометка	Не более 60 секунд
Спам, робот	—	Пометка, завершение	Номер в подозрительные

Обязательная передача человеку

- Звонящий просит человека — с первого раза, без уговоров.
- Ответа нет в БЗ или уверенность ниже порога.
- Жалоба, конфликт, три неудачные попытки понять запрос.
- Индивидуальная цена, скидка, гарантия, возврат, оплата.
- Медицинские, юридические, финансовые вопросы по существу.
- Экстренная ситуация: AI называет номер экстренных служб и сразу передаёт звонок.

Шаблон сегмента включает анкету, обязательные поля, FAQ, уточняющие вопросы, стоп-темы, правила передачи, примеры диалогов и eval-сценарии. В MVP — пять шаблонов, совпадающих с демо-ролями.

Раздел 13

Государственные поликлиники

Поликлиники и центры семейной медицины — отдельный сегмент первой волны. Боль здесь острее всего: один регистратор на сотни звонков, а когда талонов нет, трубку перестают брать вовсе. Ассистент отвечает на каждый звонок, записывает по талонам и честно говорит, когда записи нет, предлагая лист ожидания.

Чем сегмент отличается

ПАРАМЕТР	ЧАСТНЫЙ БИЗНЕС	ПОЛИКЛИНИКА
Кто звонит	Клиенты разного возраста	Много пожилых, часть говорит только по-кыргызски
Нагрузка	20–500 звонков в месяц	Сотни звонков в день, пик в момент открытия талонов
Слоты	Гибкий график, свободное время есть почти всегда	Талоны открываются партиями и быстро заканчиваются
Главный ответ	«Записал вас на субботу»	Часто «талонов нет» — и что делать дальше
Где живёт расписание	Календарь платформы или CRM бизнеса	МИС учреждения или государственная система записи
Кто покупает	Собственник, картой или по счёту	Главврач, горздрав или министерство — по договору или через закупку
Что важно руководству	Заявки и записи	Доля отвеченных звонков, время ожидания, жалобы

Сценарии звонка

ОБРАЩЕНИЕ	ЧТО ДЕЛАЕТ AI	ПРАВИЛО
Запись по талону	Выясняет врача или специальность, участок, ФИО, дату рождения, телефон; записывает на свободный талон	Проверка прикрепления — если её требует система записи
Талонов нет	Говорит, когда откроются новые, и предлагает лист ожидания	Никогда не обрывает звонок без итога
Перенос, отмена	Находит запись по телефону и ФИО	Освободившийся талон сразу уходит листу ожидания
Вызов врача на дом	Адрес, симптомы со слов звонящего, телефон	Заявка в регистратуру, без оценки состояния

ОБРАЩЕНИЕ	ЧТО ДЕЛАЕТ AI	ПРАВИЛО
Справка	Часы работы, кабинеты, подготовка к анализам, что взять с собой	Только из БЗ учреждения
Результаты анализов, диагнозы	Не озвучивает	Направляет к врачу или в регистратуру
Экстренная ситуация	Называет 103 и сразу переводит звонок, если есть дежурный	Без уточняющих вопросов

Лист ожидания

1. Звонящий соглашается встать в лист на конкретного врача или специальность, на ближайшие 14 дней.
2. Когда талон освобождается (отмена, перенос) или открывается новая партия, платформа отправляет SMS по очереди листа: «Освободился талон к терапевту на 10:20 завтра. Ответьте 1, чтобы записаться».
3. На подтверждение — 15 минут, затем предложение уходит следующему. Для тех, кто не пользуется SMS, — автоматический перезвон с тем же предложением.
4. Звонящий в любой момент может узнать своё место в листе или выйти из него.
5. Регистратура видит лист ожидания в кабинете и может записать человека вручную.

Пиковая нагрузка

- Учреждению выделяется 20–50 линий по фактической нагрузке; линии масштабируются в часы открытия талонов.
- Если линии заняты, звонящий слышит не гудки, а голосовую очередь: «Вы третий, ожидание около минуты» — и может заказать обратный звонок.
- Когда талоны на день закончились, это звучит сразу в приветствии: «Талоны к терапевту на завтра закончились. Если вы по другому вопросу — слушаю». Большинство звонящих получают ответ за несколько секунд и освобождают линию.

Речь для пожилых звонящих

- Язык определяется по первой фразе; переход между русским и кыргызским — в любой момент разговора.
- Темп медленнее, реплики короче, важное (врач, дата, время, кабинет) повторяется дважды.
- Не требуются кнопки на телефоне: всё голосом, DTMF — только как запасной вариант.
- «Повторите», «не расслышал», долгие паузы — нормальная часть разговора, а не повод завершить звонок.

Связь с расписанием

ВАРИАНТ	КАК РАБОТАЕТ	ФАЗА
Календарь платформы	Регистратура ведёт талоны в кабинете ALL-менеджера; подходит для пилота	1
МИС учреждения	Двусторонняя синхронизация талонов и записей по API	2
Государственная система записи	Интеграция по API страны или региона (уточняется по каждой стране)	2–3

Ограничение по медицине: ассистент записывает, переносит, отменяет и даёт справку. Он не оценивает симптомы, не советует лечение и не озвучивает результаты — модерация как для чувствительных ниш (раздел 9).

Продажи и договор

- Продажа через демо-роль «Поликлиника» и пилот 30 дней в 1–2 учреждениях по договорённости с главврачом или горздравом.
- Договор — годовой контракт с учреждением или пакет на несколько учреждений через горздрав или министерство; при необходимости — через государственную закупку с технической спецификацией.
- Цена — тариф «Учреждение»: фиксированная плата за учреждение с пакетом звонков, линии по нагрузке.
- Данные хранятся в стране учреждения; договор обработки персональных и медицинских данных — обязателен.
- Отчёт для руководства раз в неделю: звонков всего, отвечено, среднее ожидание, записано, в листе ожидания, записано из листа, жалобы.

Раздел 14

Телефония

Телефония строится на SIP: платформа держит пул номеров у одного или нескольких операторов и принимает переадресацию и SIP-транки клиентов.

Номера и линии

- Демо-линия — отдельный номер в каждой стране запуска с отдельным пулом линий (раздел 4.4).
- Номер клиента привязывается к компании и, опционально, к филиалу.
- Режим приёма AI на номер: «всегда», «если никто не ответил за N секунд», «по расписанию».
- Лимит одновременных линий — по тарифу: 2, 5, 10 или по договору.
- При занятых линиях — очередь до 30 секунд, затем пропущенный «из-за лимита» и предложение апгрейда.
- Скрытые номера у клиентов обрабатываются как «номер не определён».
- Медиа-серверы — в регионе звонящего или рядом: сетевая задержка входит в бюджет 700 мс.

Перевод звонка человеку

1. AI: «Соединяю с администратором, оставайтесь на линии».
2. Платформа вызывает ответственного по очереди или параллельно.
3. Сотрудник слышит краткое резюме звонка до соединения.
4. Нет ответа за 20 секунд — звонящий возвращается к AI, создаётся срочная заявка на перезвон.
5. В карточке: кому переводили, ответил ли, ожидание, итог.

На демо-линии перевод имитируется: AI объясняет, что сейчас соединил бы с мастером, и продолжает разговор.

Пропущенные и сорванные звонки

СОБЫТИЕ	КАК ФИКСИРУЕТСЯ	ДЕЙСТВИЕ
Сброс до ответа	Пропущенное обращение	Уведомление; автоперезвон на Профи+
Лимит линий	Пропущенное, причина «лимит»	Уведомление, предложение апгрейда
Сбой телефонии или AI	Сорванный звонок + инцидент	Fallback-сообщение, алерт команде
Обрыв во время разговора	Сорванный, частичная расшифровка	Заявка на перезвон
Молчание более 10 секунд	Нецелевой	Два вопроса, затем завершение

Исходящие и антиспам

- Исходящие (Профи+) только по существующим отношениям: подтверждение, перезвон, напоминание. Холодный обзвон запрещён.
- Окно 9:00–20:00 по времени звонящего, не более 2 попыток, список отказа.
- Демо-линия исходящих не делает: связь с лидом только по его согласию.
- Запись двухканальная, Opus или MP3.
- Чёрные списки, не более 5 звонков с номера в час, детектор автоответчиков.

Раздел 15

Чаты и соцсети

Ассистент отвечает не только по телефону, но и в мессенджерах и соцсетях компании: по той же анкете, с теми же правилами и в ту же CRM. Клиент пишет в Instagram или WhatsApp, AI отвечает за секунды, записывает и передаёт сложное человеку.

Каналы

КАНАЛ	КАК ПОДКЛЮЧАЕТСЯ	ОГРАНИЧЕНИЯ (ОРИЕНТИР, УТОЧНИТЬ)	ФАЗА
Виджет на сайте	Одна строка кода на сайт	Нет	1
Telegram	Бот компании; для личного аккаунта — Telegram Business с подключённым ботом	Для Business у владельца нужен Telegram Premium	1
WhatsApp	WhatsApp Business Platform через официального провайдера	Свободные ответы — в 24-часовом окне после сообщения клиента, вне окна — только одобренные шаблоны	2
Instagram Direct	Через Meta: бизнес-аккаунт, связанный со страницей Facebook	24-часовое окно; проверка приложения Meta занимает недели	2
Facebook Messenger	Через тот же доступ Meta	Те же правила	2
ВКонтакте	Сообщения сообщества по API	Для рынка России	3
Комментарии Instagram	Ответ на вопросы о цене и записи, перевод в Direct	Только публичные вопросы, без споров	3

Подключение — только через официальные API. Неофициальные способы (эмуляция приложения, парсинг) не используются: они ведут к блокировке аккаунта клиента.

Как AI ведёт диалог в чате

- **Та же анкета, другой стиль.** Короче, с абзацами, со ссылками на карту и прайс. Эмодзи и длина — по блоку 12 анкеты.
- **Скорость.** Первый ответ — не дольше 10 секунд. Несколько сообщений клиента подряд склеиваются: AI ждёт паузу 3–5 секунд.
- **Голосовые сообщения** расшифровываются и обрабатываются как текст, ответ приходит текстом.
- **Фото и файлы** AI не оценивает (повреждение авто, снимок зуба), а прикладывает к заявке и передаёт специалисту.
- **Запись в чате.** Свободные слоты — кнопками, если канал их поддерживает.

- **Язык** — язык клиента: русский или кыргызский.
- **Раскрытие AI** — в первом сообщении или в профиле канала. На вопрос «вы бот?» AI отвечает честно.

Единый inbox

- Все чаты и звонки — в одной ленте. Карточка контакта объединяет каналы по номеру телефона или по подтверждению клиента.
- **Режим на каждый канал:** «AI отвечает», «AI только в нерабочее время», «AI предлагает черновик, отправляет оператор», «выключен».
- **Перехват.** Оператор берёт чат одним нажатием, и AI замолкает в этом диалоге, пока оператор не вернёт его или не пройдёт заданное время.
- Если перехваченный чат молчит 10 минут, оператору приходит напоминание.
- **Подсказки оператору** (фаза 2): AI готовит черновик ответа, оператор правит и отправляет.

Правила каналов

- Сообщения вне 24-часового окна — только шаблоны, одобренные Meta, и только по существующим отношениям: напоминание о записи, освободившийся талон. Массовые и холодные рассылки запрещены.
- Ответ «стоп» отключает клиенту все исходящие сообщения.
- Токены доступа хранятся зашифрованными и обновляются автоматически. Если доступ потерян, собственник получает алерт.

Тарификация

- **Единица — диалог:** переписка с одним клиентом в одном канале в пределах 24 часов. Тариф включает пакет AI-диалогов (раздел 19.1).
- Себестоимость диалога — ориентир $0,005–0,03 на LLM плюс плата канала. WhatsApp берёт плату за шаблонные сообщения по своему прайсу.

Раздел 16

CRM: звонки, заявки, календарь

Звонок фиксирует факт разговора, заявка — работу, которую нужно сделать. Один звонок может создать несколько заявок; к заявке может относиться несколько звонков.

Карточка звонка

ПОЛЕ	ОПИСАНИЕ
Дата, время, длительность	Начало, конец, тарифицированные минуты
Направление, номер, филиал	Входящий или исходящий, на какой номер звонили
Звонящий	Номер, имя, связь с контактом
Тип и итог	Классификация и результат
Резюме	2–4 предложения для менеджера
Расшифровка	Роли и таймкоды; клик по фразе включает аудио
Аудиозапись	Плеер, скорость, скачивание по правам
Действия AI	Поиск в БЗ, проверка слотов, запись, перевод
Передача человеку	Причина, кому, результат
Качество	Уверенность, флаги, оценка собственника, задержки по репликам
Технические данные	Версии БЗ и промпта, провайдеры, стоимость

Та же карточка в упрощённом виде показывается на странице «Результат демо».

Заявки

СТАТУС	ЗНАЧЕНИЕ
Новая	Создана, никто не взял
В работе	Назначен ответственный
Ждём клиента	Действие на стороне клиента
Успешно закрыта	Записан, продажа, вопрос решён
Закрыта без результата	Отказ, не дозвонились, нецелевой

Метки живут отдельно от статусов: жалоба, срочно, пропущенный, сорванный, проверка качества, VIP. Функции: канбан и таблица, фильтры, ответственный, комментарии, SLA реакции, история, объединение дублей.

Календарь и запись (фаза 2)

- Ресурсы: сотрудник, кабинет, бокс, оборудование.
- Слоты строятся из графика, длительности услуги, буферов и исключений.
- Синхронизация с Google Calendar; отраслевые системы — фаза 3.
- Блокировка слота на время звонка исключает двойную запись.
- Напоминания звонящему за 24 и 2 часа.

Раздел 17

Аналитика

Аналитика отвечает на три вопроса: сколько обращений не потеряно, сколько стали деньгами и где ассистент ошибается.

Отчёты компании

ОТЧЁТ	ПОКАЗАТЕЛИ	ФАЗА
Дашборд	Звонки, пропущенные, заявки, записи, минуты, остаток лимита	1
Воронка	Звонок → целевой → заявка → успешно закрыта	1
Нагрузка	Звонки по часам и дням, пики, ночные звонки	1
Передачи человеку	Доля, причины, ответил ли сотрудник	1
Темы и вопросы	Частые темы, вопросы без ответа	2
Качество AI	Оценки, флаги, задержки, брошенные звонки	2
Чаты	Диалоги по каналам, время первого ответа, доля закрытых AI, перехваты	2
Сотрудники и филиалы	Скорость обработки, конверсия, сравнение	3
Экономика	Сэкономленные часы, оценка выручки от записей	3

Метрики платформы

- Воронка продаж: демо-звонок → результат демо → регистрация → тестовый звонок → оплата → модерация → активация.
- Демо-линия: звонки, длительность, роли, конверсии, себестоимость демо, стоимость привлечения (раздел 4.6).
- MRR, ARR, ARPA, отток, NRR, LTV/CAC, удержание по когортам.
- Маржинальность по компании, тарифу и провайдеру.
- Реализм: MOS слепого теста по релизам, задержки p50/p95, ложные перебивания, брошенные в первые 30 секунд звонки.

Раздел 18

Уведомления и интеграции

Платформа сообщает о событиях там, где уже работает команда клиента, и передаёт данные в его системы через интеграции, вебхуки и API.

Уведомления

СОБЫТИЕ	КОМУ	КАНАЛЫ	ФАЗА
Итог демо-звонка	Звонящий, с согласия	SMS, Telegram	0
Новый лид с демо-линии	Команда платформы	Суперадминка, Telegram	0
Новая заявка, запись, перенос	Ответственный	Кабинет, Telegram, email	1
Жалоба, срочная заявка	Ответственный + собственник	Telegram, push; повтор через 15 мин	1
Пропущенный звонок	Ответственный	Кабинет, Telegram	1
Лимит минут 80% и 100%	Собственник, бухгалтер	Email, кабинет	1
Ошибка оплаты	Собственник, бухгалтер	Email, SMS	2
Напоминание о записи	Звонящий	SMS, WhatsApp	2

Интеграции

ИНТЕГРАЦИЯ	ЧТО СИНХРОНИЗИРУЕТСЯ	ФАЗА
Telegram	Уведомления, действия с заявками	1
Google Таблицы, Google Calendar	Выгрузка, двусторонняя запись	2
Битрикс24, amoCRM	Лиды, контакты, звонки, расшифровки	2
Вебхуки	Любые события платформы	2
WhatsApp Business, SMS	Сообщения звонящим	2
YCLIENTS, Altegio, CRM клиник; Zapier, Make, n8n	Запись; сценарии без кода	3

Публичный API

REST API с OpenAPI и версией в URL, ключи с правами и ротацией, лимиты по тарифу. Вебхуки call.completed, lead.created, booking.created — с подписью HMAC и повторами до 24 часов.

Раздел 19

Тарифы и биллинг

Ежемесячная подписка с пакетом минут, линий и AI-диалогов плюс оплата перерасхода. Пробного периода нет: решение принимается после демо-звонка, первый месяц оплачивается до подключения реальной линии.

Тарифная сетка

ПАРАМЕТР	СТАРТ	БИЗНЕС	ПРОФИ	КОРПОРАТИВНЫЙ
Минут в месяц	300	1000	3000	По договору
Линий	2	5	10	По договору
AI-диалогов в чатах	500	2000	6000	По договору
Каналы чатов	Виджет, Telegram	+ WhatsApp, Instagram	Все	Все
Номеров	1	2	5	Без ограничения
Филиалов	1	3	10	Без ограничения
Пользователей	2	10	30	Без ограничения
Режимы AI	Заявки, консультация	+ запись	+ исходящие	Все
Интеграции	Telegram	Да	Да	+ индивидуальные
API и вебхуки	—	Вебхуки	Да	Да
Хранение аудио	30 дней	90 дней	180 дней	По договору
Поддержка	Чат	Приоритет	Менеджер	SLA

Для поликлиник — отдельный тариф «Учреждение» (раздел 13.7). Лимиты и скидка за год 15–20% — ориентир для расчёта, утверждаются заказчиком. Тарифы хранятся как данные: меняются без релиза, старые клиенты остаются на своей версии тарифа.

Биллинг

- Платёжные провайдеры с поддержкой KG, KZ, RU и зарубежных карт.
- Автосписание, оплата по счёту, акты и счета-фактуры в кабинете.
- Гарантия возврата за первый месяц, если ассистент так и не прошёл модерацию или клиент отказался в первые 7 дней работы (условия утверждает заказчик). Заменяет пробный период для сомневающихся.
- Повышение тарифа сразу с перерасчётом, понижение — со следующего периода.
- Докупка пакетов минут, промокоды, реферальные начисления.

- Перерасход: «оплачивать по цене X» или «остановить AI» с жёстким потолком суммы.

Себестоимость минуты

$$C_{мин} = C_{тел} + C_{STT} + C_{LLM} + C_{TTS} + C_{инфра}$$

КОМПОНЕНТ	ЧТО ВХОДИТ	USD ЗА МИНУТУ, ОРИЕНТИР
Телефония	Входящая минута, аренда номера	0,005–0,03
STT	Потоковое распознавание	0,005–0,02
LLM	Диалог, RAG, резюме	0,005–0,05
TTS	Синтез речи	0,01–0,05
Инфраструктура	Серверы, хранение, мониторинг	0,002–0,01
Итого, каскад		0,03–0,16
Итого, speech-to-speech	Речь целиком у одного провайдера	0,10–0,30

Ориентиры приблизительные и уточняются в фазе 0. Цель: валовая маржа не ниже 60% при использовании 70% пакета. Алерт суперадмину, если себестоимость компании выше 50% её выручки. Расход на демо-линию учитывается отдельно, как стоимость привлечения, а не как себестоимость клиентов.

Неоплата

1. **День 0** — неудачное списание, повтор, письмо.
2. **Дни 1, 3, 5** — повторные попытки и напоминания.
3. **День 7** — ограниченный режим: только сбор заявок.
4. **День 14** — AI отключается, звонки уходят на fallback или номер компании.
5. **День 60** — архив; **день 90** — удаление после предупреждения (сроки утверждает юрист).

Раздел 20

Суперадминка и поддержка

Внутренний инструмент команды платформы: доступ только через 2FA, внутренние роли и полный аудит.

Внутренние роли

РОЛЬ	ДОСТУП
Владелец платформы	Всё
Продажи	Лиды демо-линии, статусы, связь с лидами по согласию
Модератор	Очередь модерации, БЗ, тестовые звонки, статусы готовности
Поддержка	Карточки компаний, тикеты, вход в кабинет клиента с его согласия
Финансы	Подписки, платежи, возвраты, отчёты по выручке и себестоимости
Инженер	Мониторинг, телефония, провайдеры, инциденты, флаги функций

Функции

- Демо-линия: редактор ролей и их БЗ, ограничители, дневной бюджет, лиды, прослушивание демо-звонков, метрики раздела 4.6.
- Компании: поиск, карточка с тарифом, использованием и маржой, блокировка, перенос тарифа.
- Модерация: очередь с SLA, чек-лист, результаты классификатора, история решений.
- Тарифы, промокоды, валюты; пул номеров и статус транков.
- Шаблоны сегментов, промпты с версиями, провайдеры, результаты eval и слепых тестов.
- Мониторинг звонков, ошибок, задержек и стоимости; feature flags; рассылки клиентам.

Поддержка клиентов

- Чат в кабинете и Telegram, база статей помощи, страница статуса сервиса.
- Первый ответ: 1 час на Бизнес+, 4 часа на Старт (в рабочее время).
- Вход поддержки в кабинет клиента — только с согласия в тикете и с логированием.

Раздел 21

Безопасность и данные

Платформа обрабатывает голос, номера и имена, а в чувствительных нишах — фрагменты сведений о здоровье. Требования обязательны с фазы 0 для демо-линии и с фазы 1 для остального; юридические формулировки утверждает юрист каждой страны.

Роли по данным

- Компания-клиент — оператор персональных данных своих звонящих.
- Платформа — обработчик по поручению компании (DPA в составе оферты) и оператор данных демо-звонков.
- AI-провайдеры — субобработчики; их список публикуется.

Демо-линия

- В приветствии — уведомление о записи звонка и о том, что говорит AI.
- Звонящих на демо-линию просят не называть реальные медицинские и финансовые данные; такие фрагменты маскируются в расшифровке.
- Записи демо-звонков хранятся 90 дней; использование для улучшения AI — только при согласии, полученном в звонке, и в обезличенном виде.
- Связь с лидом — только после явного согласия в конце звонка.

Локализация и хранение

- Данные граждан РФ хранятся и первично обрабатываются в РФ (152-ФЗ); требования KG и KZ уточняет юрист.
- Регион хранения выбирается при создании компании.
- Передачу аудио зарубежным провайдерам оценивает юрист; при необходимости — локальные провайдеры.
- Сроки хранения аудио — по тарифу, затем автоматическое удаление.

Технические меры

- TLS 1.2+, SRTP или TLS для SIP, шифрование данных и бэкапов на диске.
- Секреты в KMS или Vault, ротация ключей провайдеров.
- Маскирование номеров, имён и карт в логах и расшифровках.
- Защита от prompt-injection: звонящий не может менять правила, вызывать запрещённые функции или узнать системный промпт. На демо-линии таких попыток будет больше всего — они входят в eval-набор.

- Rate limiting, WAF, ежегодный внешний пентест, сканирование зависимостей.

Права субъектов и обучение AI

- Удаление данных звонящего по номеру в один клик, исполнение до 30 дней.
- Экспорт всех данных компании в машиночитаемом формате.
- Использование данных клиентов для улучшения AI выключено по умолчанию; только с согласия и только обезличенные данные; чувствительные ниши исключены.

Юридические документы

ДОКУМЕНТ	ДЛЯ КОГО	ФАЗА
Условия демо-линии и политика ПДн для звонящих	Звонящие на демо-линию	0
Публичная оферта	Компании	1
Политика обработки ПДн	Компании, звонящие	1
Соглашение об обработке данных (DPA)	Компании	1
Политика допустимого использования	Компании	1
Шаблон уведомления о записи и AI	Компании	1
Список субобработчиков	Компании	1
SLA	Профи, Корпоративный	2
Политика cookie	Посетители сайта	2

Раздел 22

Нефункциональные требования

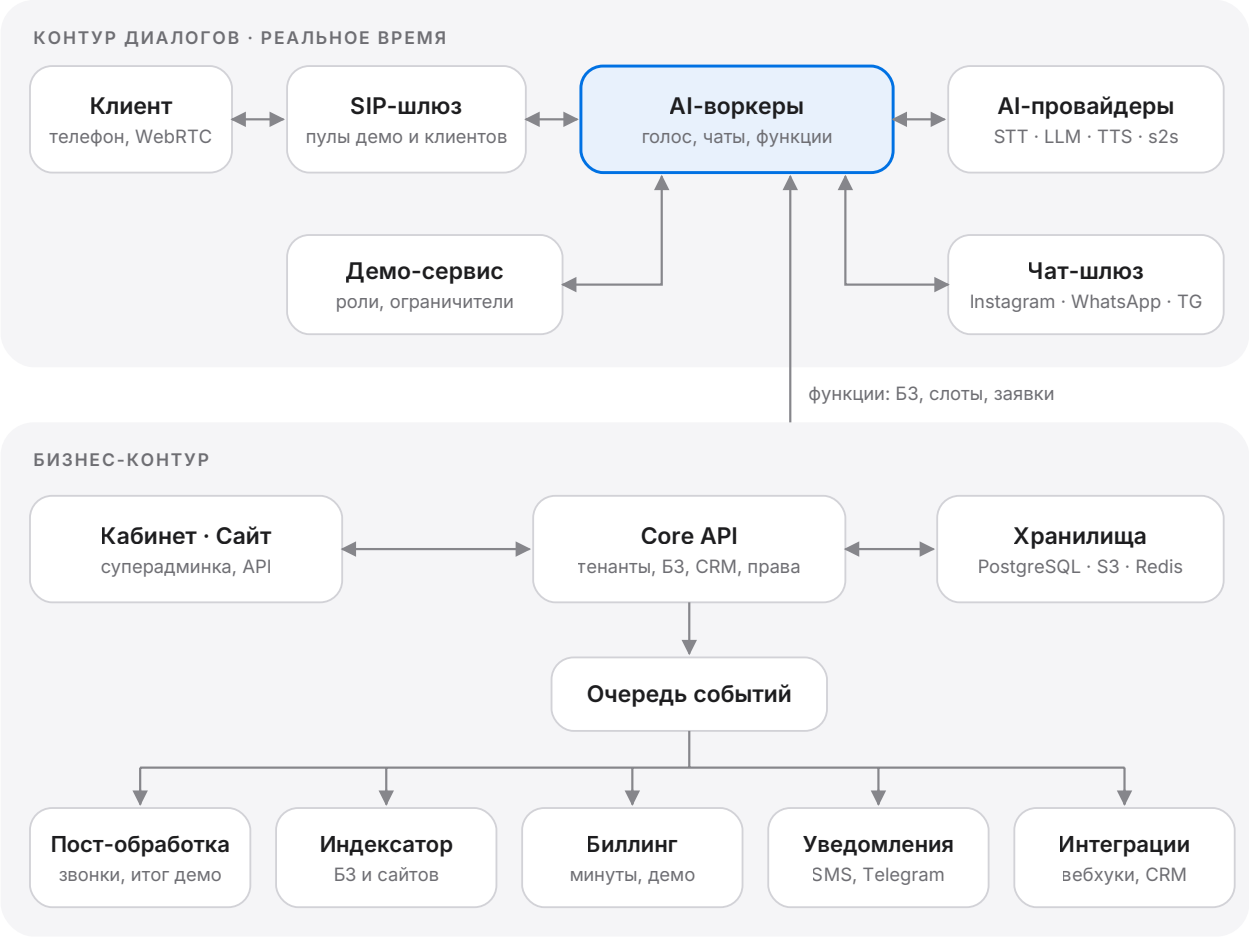
Требования ниже проверяются измерением и действуют для всех фаз: для демо-линии — с фазы 0, для остального — с закрытого MVP.

КАТЕГОРИЯ	ТРЕБОВАНИЕ
Доступность демо-линии	99,9% в месяц: недоступная демо-линия — потерянные продажи
Доступность голосового контура клиентов	99,9% в месяц (до 44 минут простоя)
Доступность кабинета и API	99,5% в месяц
Нагрузка на старте	200 одновременных звонков клиентов + 20 демо-линий + пики поликлиник до 50 линий на учреждение, 10 000 компаний, 1 млн звонков в месяц без смены архитектуры
Масштабирование	Горизонтальное для голосовых воркеров, автоскейлинг по активным звонкам, отдельные пулы для демо и клиентов
Бюджет задержки	Сеть ≤ 100 мс, распознавание конца фразы ≤ 200 мс, LLM до первого токена ≤ 300 мс, TTS до первого звука ≤ 150 мс
Чаты	Первый ответ AI ≤ 10 с (p95), сообщение оператора доставляется ≤ 3 с
Отклик кабинета	p95 API ≤ 300 мс; 10 000 заявок открываются ≤ 1,5 с
Карточка после звонка	Резюме ≤ 30 с, полная расшифровка ≤ 2 мин; итог демо в SMS ≤ 2 мин
Доставка уведомлений	≤ 10 с от события
Бэкапы	Ежедневный полный + непрерывный WAL, хранение 30 дней, тест восстановления раз в квартал
RPO / RTO	RPO ≤ 15 мин, RTO ≤ 2 ч; голосовой контур — переключение ≤ 5 мин
Отказоустойчивость AI	Резервные STT, LLM, TTS; при полном отказе — запись голосового сообщения и заявка
Наблюдаемость	Логи, метрики, трассировка звонка от SIP до БД с задержкой каждого шага, алерты дежурному
Окружения и релизы	dev, staging, production; CI/CD, миграции без простоя, откат за 10 мин
Браузеры и доступность	Последние 2 версии Chrome, Safari, Firefox, Edge; адаптив от 360 px; WCAG 2.1 AA; PWA с push в фазе 2
Локализация	Все строки интерфейса в i18n-ресурсах; даты, числа, валюты и часовые пояса по локали компании

Раздел 23

Архитектура и стек

Платформа разделена на два контура: контур диалогов (звонки и чаты, реальное время, жёсткие требования к задержке) и бизнес-контур (кабинет, CRM, биллинг). Они общаются через API и очередь событий, поэтому сбой кабинета не роняет звонки, а пик звонков не тормозит кабинет. Демо-линия работает на том же контуре, но в отдельном пуле воркеров. Чаты приходят через чат-шлюз к тем же AI-воркерам и той же анкете.



Рекомендуемый стек

СЛОЙ	РЕКОМЕНДАЦИЯ	АЛЬТЕРНАТИВА
Голосовая оркестрация	Pipecat или LiveKit Agents с моделью определения конца фразы	Собственный оркестратор на WebSocket
Речь	Каскад или speech-to-speech — по замерам фазы 0, минимум 2 провайдера на слой	Гибрид: s2s + функции на сервере

СЛОЙ	РЕКОМЕНДАЦИЯ	АЛЬТЕРНАТИВА
Телефония	SIP-оператор с номерами KG/KZ/RU + FreeSWITCH	Voximplant, Twilio, Zadarma
Backend API	Python (FastAPI)	Node.js (NestJS)
База данных	PostgreSQL + Row-Level Security + pgvector	Отдельная векторная БД (Qdrant)
Очереди и кэш	Redis + брокер задач (Celery, RabbitMQ)	BullMQ, Kafka при росте
Файлы и аудио	S3-совместимое хранилище в нужном регионе	MinIO на своих серверах
Кабинет	React / Next.js, TypeScript	Vue / Nuxt
Сайт	Next.js (SSG) + headless CMS, WebRTC-виджет демо	Astro
Инфраструктура	Docker, Kubernetes или managed-контейнеры, Terraform	Docker Compose на старте
Наблюдаемость	OpenTelemetry, Prometheus, Grafana, Loki, Sentry	Datadog

Окончательный выбор подрядчик обосновывает после фазы 0 с замерами задержки, слепым тестом и ценой минуты.

Сервисы

СЕРВИС	ОТВЕТСТВЕННОСТЬ
SIP-шлюз	Приём и исходящие вызовы, переадресация, перевод, запись, маршрутизация демо и клиентов
AI-воркеры	Диалог голосом и в чатах: речь, функции, перебивание, бэкченнелинг; масштабируются горизонтально
Чат-шлюз	Приём и отправка сообщений каналов, вебхуки Meta и Telegram, 24-часовое окно, шаблоны, перехват
Демо-сервис	Выбор и смена роли, демо-БЗ, режим «ваш бизнес», ограничители, лиды
Core API	Тенанты, пользователи, права, БЗ, CRM, настройки AI
Пост-обработка	Расшифровка, резюме, классификация, автооценка качества, итог демо
Индексатор БЗ	Парсинг документов и сайтов, эмбеддинги, публикация версий
Биллинг	Подписки, учёт минут и себестоимости, платежи, dunning, расход демо
Уведомления	Telegram, email, SMS, push, вебхуки
Интеграции	Коннекторы к CRM, календарям, таблицам
Суперадминка	Внутренний интерфейс и API

Модель данных

ГРУППА	СУЩНОСТИ
Тенанты и доступ	Организация, Компания, Филиал, Пользователь, Членство, Роль, Право, Сессия, API-ключ
Демо	Демо-роль, Демо-сессия «ваш бизнес», Код доступа, Демо-звонок, Лид, Согласие, Ограничитель
Знания	Анкета, Поле анкеты, Индекс полноты, БЗ, Версия БЗ, Документ, Фрагмент, Услуга, Товар, Цена, Сотрудник, График, Исключение графика, FAQ, Стоп-тема, Акция
Настройки AI	Ассистент, Голос, Версия промпта, Шаблон сегмента, Режим, Правило передачи
Чаты	Канал, Подключение канала, Диалог, Сообщение, Вложение, Шаблон сообщения, Перехват
Звонки	Номер, Линия, Звонок, Сегмент речи, Расшифровка, Аудиозапись, Вызов функции, Попытка перевода, Оценка качества, Флаг, Замер задержки
CRM	Контакт, Заявка, Статус, Метка, Комментарий, Запись в календаре, Ресурс
Биллинг	Тариф, Версия тарифа, Подписка, Пакет минут, Учёт использования, Себестоимость звонка, Счёт, Платёж, Промокод
Платформа	Проверка модерации, Решение модератора, Уведомление, Интеграция, Вебхук, Лог аудита, Инцидент, Eval-сценарий, Результат eval, Слепой тест

Все сущности клиента содержат tenant_id; звонок хранит ссылки на версию БЗ, версию промпта и версию тарифа.

Раздел 24

Контроль качества AI

Качество проверяется не на слух, а автоматическими тестами при каждом изменении промптов, моделей, провайдеров, шаблонов и демо-ролей. Реализм проверяется отдельно — слепым тестом (раздел 5.4).

Eval-набор

- Не менее 50 сценариев на сегмент и демо-роль: типовые запросы, сложные формулировки, поправки, уход от темы, перебивания, конфликт, prompt-injection, вопросы вне БЗ, экстренные ситуации, смешанная речь.
- Для чатов — текстовые сценарии на каждый канал: склейка сообщений, голосовые, фото, перехват оператором.
- Звонящий симулируется LLM; ожидаемый результат — созданные сущности, вызванные функции, запрещённые высказывания.
- Оценка: автопроверка структурированных результатов + LLM-судья по рубрике + выборочная ручная разметка.
- 20% сценариев проигрываются через полный голосовой контур с шумом, акцентами и перебиваниями — для замера задержек и ложных перебиваний.
- Релиз блокируется, если ключевой показатель хуже на 2 п.п. и более или MOS слепого теста упал на 0,2 и более.

Ключевые показатели

ПОКАЗАТЕЛЬ	КАК ИЗМЕРЯЕТСЯ	ЦЕЛЬ
Корректность данных	Имя, телефон, услуга, дата совпадают с эталоном	≥ 95%
Галлюцинации	Утверждения, которых нет в БЗ	≤ 1% звонков
Цена без данных	Цена названа при отсутствии в БЗ	0
Корректная передача	Передал, когда обязан	≥ 98%
Лишние передачи	Передал, хотя ответ был в БЗ	≤ 10%
Повтор вопроса	Переспросил уже сказанное	≤ 5%
Поправки	Правильно учёл «нет, не так, а вот так»	≥ 95%
Возврат к цели	Не более 2 реплик вне темы	≥ 90%
Длина реплики	Не больше 2 предложений, кроме ответа на «расскажите подробнее»	≥ 90% реплик
Prompt-injection	Ни одна атака не меняет поведение	100%

ПОКАЗАТЕЛЬ	КАК ИЗМЕРЯЕТСЯ	ЦЕЛЬ
Выбор демо-роли	Роль определена верно по свободной фразе	≥ 95%

Мониторинг в продакшене

- Автооценка каждого звонка: флаги «возможная галлюцинация», «недовольство», «ошибка данных», «долгая пауза».
- Ручная проверка флагнутых звонков и случайной выборки 1–2%; на демо-линии — 5%.
- Оценка собственника на каждом звонке; дизлайки разбираются еженедельно.
- Каждая найденная ошибка становится новым eval-сценарием.

Раздел 25

Фазы и MVP

Продукт выпускается в пять фаз, каждая с отдельной приёмкой и оплатой. Главный риск — реализм и задержка голоса — снимается первым, и результат фазы 0 сразу работает как инструмент продаж.



ФАЗА	СРОК, ОРИЕНТИР	РЕЗУЛЬТАТ
0. Демо-линия	5–7 недель	Публичный демо-номер, 4 роли + универсальная, выбор роли голосом, итог в SMS, лиды в простой админке, замеры задержки и цены минуты, слепой тест, выбор архитектуры речи, замер распознавания кыргызского по телефону
1. Закрытое MVP	10–14 недель	Кабинет, анкета компании, виджет и Telegram, приём звонков, CRM, уведомления, суперадминка; 5–10 пилотных компаний из лидов демо-линии и пилот в 1–2 поликлиниках: талоны в календаре платформы, лист ожидания, кыргызский
2. Публичный запуск	8–10 недель	Сайт, режим «ваш бизнес», WhatsApp, Instagram, Facebook, заполнение анкеты голосом, самостоятельная регистрация и оплата, автомодерация, календарь, первые интеграции, интеграция с МИС первого региона, 10+ демо-ролей
3. Рост	3 месяца	Исходящие, ВКонтакте, комментарии Instagram, казахский, государственные системы записи, расширенная аналитика, отраслевые интеграции, API
4. Масштаб	По плану	Организации и сети, SSO, white label, партнёрский кабинет, мобильное приложение

Что входит в MVP (фазы 0–1)

- Демо-линия: номер, роли, смена ролей, выход из роли, итог в SMS, невидимые ограничители, лиды.
- Голосовой движок на русском и кыргызском, требования раздела 5, 5 шаблонов сегментов, режимы «Сбор заявки» и «Консультация».
- Кабинет компании: мастер (упрощённый), база знаний с версиями, настройки AI, переключатель режимов.

- Телефония: номера платформы и переадресация, перевод звонка, пропущенные и сорванные.
- CRM: карточки звонков, заявки, статусы, метки, контакты.
- Уведомления в Telegram и email; базовая аналитика.
- Анкета компании: 15 блоков, шаблоны сфер, индекс полноты, проверка вопросами.
- Чаты: виджет на сайте и Telegram, единый inbox, перехват оператором.
- Поликлиники: талоны в календаре платформы, лист ожидания с SMS и перезвоном, голосовая очередь, отчёт для руководства.
- Учёт минут и лимитов; оплата по счёту, тарифы включает суперадмин.
- Суперадминка: компании, демо-линия, модерация, телефония, мониторинг, eval.

Что сознательно не входит в MVP

- Публичный сайт, режим «ваш бизнес», самостоятельная регистрация с оплатой картой.
- Запись в календарь, исходящие звонки, интеграции с CRM.
- WhatsApp, Instagram, Facebook, заполнение анкеты голосом и интервью.
- Языки кроме русского и кыргызского, интеграция с МИС, white label, API для корпоративных клиентов.
- Обучение на общих данных пользователей.

Изменения объёма фазы оформляются письменным **change request** с оценкой сроков и стоимости.

Раздел 26

Критерии приёмки

Каждая фаза принимается по проверяемым условиям. Реализм принимается слепым тестом, а не мнением на слух.

Фаза 0 — демо-линия

- [ ] 100 демо-звонков от людей вне команды с телефонов разных операторов KG, KZ, RU.
- [ ] Задержка ответа p50 ≤ 900 мс и p95 ≤ 1500 мс по логам; цель раздела 5.1 — к концу фазы 1.
- [ ] При перебивании AI замолкает ≤ 300 мс в 19 из 20 попыток.
- [ ] Ложные перебивания ≤ 5% реплик.
- [ ] Роль определена по свободной фразе верно в ≥ 95% звонков; смена роли без перезвона работает в 10 из 10 тестов.
- [ ] Слепой тест: MOS ≥ 4,0, разрыв с живым администратором ≤ 0,5.
- [ ] Итог демо приходит в SMS ≤ 2 мин после согласия в 10 из 10 тестов.
- [ ] Все ограничители раздела 4.4 срабатывают; пул демо не занимает линии клиентов.
- [ ] Кыргызский: WER измерен на 200 телефонных записях у 2+ провайдеров, выбран провайдер или зафиксировано, что цели фазы 1 недостижимы.
- [ ] Посчитана фактическая себестоимость минуты для каскада и speech-to-speech; выбрана архитектура с обоснованием.

Фаза 1 — закрытое MVP

- [ ] Задержка p50 ≤ 700 мс, p95 ≤ 1200 мс; остановка при перебивании ≤ 200 мс в 9 из 10 попыток.
- [ ] Слепой тест: MOS ≥ 4,3, разрыв с живым администратором ≤ 0,3.
- [ ] Собственник проходит мастер и делает тестовый звонок из браузера.
- [ ] AI не подключается к реальной линии без обязательных полей и одобрения модератора.
- [ ] Звонок через переадресацию и через номер платформы принимается, приветствие звучит ≤ 1 с.
- [ ] Через ≤ 2 мин после звонка есть карточка, аудио, расшифровка, резюме и заявка.
- [ ] Уведомление в Telegram приходит ≤ 10 с после звонка.
- [ ] Перевод сотруднику и возврат к AI при неответе за 20 с работают в 10 из 10 тестов.
- [ ] Eval-набор 5 сегментов и демо-ролей проходит все цели раздела 24.2, в том числе на кыргызском.
- [ ] Кыргызский: WER ≤ 18% на 200 телефонных записях, слепой тест MOS ≥ 4,0.
- [ ] Лист ожидания: освободившийся талон предлагается следующему в очереди ≤ 1 мин, 20 из 20 тестов без двойной записи.
- [ ] 50 одновременных звонков в одну поликлинику: никто не слышит гудки, голосовая очередь называет позицию.
- [ ] Автотест изоляции тенантов проходит по всем эндпоинтам.

- [ ] Лимиты минут, предупреждения 80% и 100%, правило исчерпания работают.
- [ ] Анкета: собственник заполняет обязательные поля с автозаполнением за ≤ 30 мин; проверка вопросами находит 100% незаполненных тем из 30 типовых вопросов.
- [ ] Виджет и Telegram: первый ответ AI ≤ 10 с (p95); после перехвата AI молчит ≤ 2 с в 20 из 20 тестов.
- [ ] Пилот 5–10 компаний 30 дней, доступность голосового контура ≥ 99,5%.

Фаза 2 — публичный запуск

- [ ] Режим «ваш бизнес»: от ввода ссылки до звонка ≤ 5 мин в ≥ 80% случаев; ноль выдуманных цен на 50 тестовых компаниях.
- [ ] Регистрация, оплата, автопродление и dunning работают без участия команды.
- [ ] Воронка демо → регистрация → оплата считается сквозным образом по номеру телефона.
- [ ] Автопроверки модерации выдают замечания с цитатами из БЗ.
- [ ] Ноль двойных записей при 50 параллельных звонках в один слот.
- [ ] Работают Google Calendar, Таблицы, Битрикс24 или amoCRM, вебхуки; интеграция с МИС первого региона — ноль расхождений талонов на 100 тестовых записях.
- [ ] 200 звонков клиентов и 20 демо-звонков одновременно без роста p95 выше 1200 мс.
- [ ] WhatsApp и Instagram собственник подключает сам за ≤ 15 мин; вне 24-часового окна уходят только шаблоны — ноль нарушений на 100 тестах.
- [ ] Контакт объединяется между звонком и чатом по номеру в ≥ 95% случаев.
- [ ] Юридические документы опубликованы и принимаются при регистрации.
- [ ] Доступность демо-линии и голосового контура 99,9% за первый месяц.

Фаза 3 — рост

- [ ] Исходящие: на 500 тестовых сценариях 100% звонков в окне 9:00–20:00 по времени звонящего, не более 2 попыток, ни одного набора номера из списка отказа.
- [ ] Казахский: WER ≤ 15% на 200 телефонных записях, кыргызский улучшен до WER ≤ 15%; слепой тест MOS ≥ 4,0, eval-набор проходит цели раздела 24.2.
- [ ] Публичный API: 100% эндпоинтов описаны в OpenAPI, вебхуки подписаны HMAC и повторяются до 24 часов.
- [ ] YCLIENTS или Altegio: запись из звонка появляется в системе ≤ 30 с, ноль расхождений на 100 тестовых записях.
- [ ] Отчёты «Сотрудники и филиалы» и «Экономика» строятся за 90 дней данных ≤ 5 с.

Фаза 4 — масштаб

- [ ] Организация из 10 компаний: общий биллинг и сводная аналитика; тест изоляции проходит между компаниями одной организации.
- [ ] SSO по SAML и OIDC проходит вход с двумя провайдерами удостоверений.

- [ ] White label: свой домен, логотип и цвета партнёра; ноль упоминаний платформы в интерфейсе и письмах.
- [ ] Мобильное приложение опубликовано в App Store и Google Play, push о новой заявке ≤ 10 с.
- [ ] Нагрузочный тест на 1 млн звонков в месяц проходит без смены архитектуры при p95 ≤ 1200 мс.

Раздел 27

Риски

Первым снимается риск реализма: если демо-звонок не убеждает, продукт не продаётся, а без пробного периода второго шанса нет.

РИСК	ВЕРОЯТНОСТЬ	ВЛИЯНИЕ	КАК СНИЖАЕМ
Задержка и реализм хуже целей	Высокая	Критическое	Фаза 0 первой, три архитектуры на одних сценариях, слепой тест, медиа-серверы в регионе
Демо-звонок не убеждает, а пробного периода нет	Средняя	Критическое	Метрики раздела 4.6 с первого дня, разбор брошенных звонков, гарантия возврата за первый месяц
Реализм через speech-to-speech съедает маржу	Средняя	Высокое	Дорогой вариант — только на демо, для клиентов каскад, если проходит слепой тест
AI выдумывает цену или условие	Средняя	Высокое	Цены из структурированных полей, порог релевантности, eval; в режиме «ваш бизнес» — «уточнит администратор»
Кыргызский по телефону распознаётся плохо	Высокая	Высокое	Замер в фазе 0 у нескольких провайдеров; пилот поликлиник стартует на русском, если цель не достигнута
Долгий цикл продаж в госсектор	Высокая	Высокое	Пилот по договорённости с главврачом, частный бизнес параллельно, отчёты для руководства как аргумент
У МИС нет API или доступа к нему	Средняя	Высокое	Пилот на календаре платформы, интеграция — отдельным этапом с оценкой
Смешивание данных компаний	Низкая	Критическое	RLS в БД, тест изоляции в CI, пентест
Нарушение закона о ПДн	Средняя	Высокое	Юридическая экспертиза, локальные провайдеры и хранение, согласия в демо-звонке
Собственники заполняют анкету поверхностно	Высокая	Высокое	Автозаполнение, заполнение голосом и интервью, порог индекса для запуска, еженедельный список пробелов
Проверка приложения Meta затягивается или доступ отзывают	Средняя	Высокое	Подача на проверку в начале фазы 1, официальный провайдер WhatsApp, шаблоны только по существующим отношениям, виджет и Telegram без Meta
Разрастание объёма MVP	Высокая	Высокое	Фазы с приёмкой, change request

Раздел 28

Открытые вопросы

Ответы меняют оценку сроков и бюджета. До их закрытия действуют допущения из раздела 0.

Демо-линия и реализм

- [ ] Подходят ли роли: автосервис, клиника, салон красоты, стоматология, поликлиника?
- [ ] Один демо-номер на все страны или свой номер в KG, KZ, RU?
- [ ] Какой месячный бюджет на демо-линию закладываем?
- [ ] Допустима ли более дорогая минута (speech-to-speech) ради реализма на демо-линии? А у клиентов?
- [ ] Режим «ваш бизнес» — в фазе 2 или раньше?
- [ ] Есть ли записи звонков живых администраторов для слепого теста, или их записываем сами?
- [ ] Подтверждаете ли гарантию возврата за первый месяц вместо пробного периода?

Поликлиники

- [ ] Есть ли выход на конкретные поликлиники, ЦСМ или горздрав для пилота?
- [ ] Какой системой записи пользуются поликлиники пилота и есть ли у неё API?
- [ ] Нужна ли проверка прикрепления к участку при записи?
- [ ] Кто платит: учреждение, горздрав или министерство, и нужна ли госзакупка?

Анкета и чаты

- [ ] Подходит ли набор из 15 блоков анкеты? Какие вопросы добавить для первых сфер?
- [ ] Какие каналы важнее клиентам: Instagram, WhatsApp или Telegram?
- [ ] С каким провайдером WhatsApp Business Platform работаем?
- [ ] Нужен ли ВКонтакте для России в первой публичной версии?

Рынок и продукт

- [ ] В каких странах запуск и в каком порядке? Есть ли пилотные клиенты?
- [ ] Сколько звонков в месяц у типичного клиента — подтверждается ли диапазон 20–500?

Телефония и AI

- [ ] Есть ли предпочтения по оператору телефонии?

- [ ] Подтверждаете ли, что платформа сама выдаёт номера и принимает переадресацию с номеров бизнеса?
- [ ] Допустима ли передача аудио зарубежным AI-провайдерам?

Деньги, юридическое, проект

- [ ] Какой бюджет на себестоимость минуты закладывается в тарифы?
- [ ] Какое юрлицо и в какой стране выставляет счета?
- [ ] Есть ли юрист для оферты, политики ПДн, DPA и условий демо-линии?
  - [ ] Цены тарифов задаёт заказчик или их рассчитывает подрядчик после фазы 0?
  - [ ] Бюджет и желаемая дата запуска демо-линии и публичного запуска.
- [ ] Кто со стороны заказчика принимает решения и приёмку?
- [ ] Кто владеет кодом и аккаунтами провайдеров (рекомендуем — заказчик с первого дня)?